


Basic Neural Networks



~~Siapa~~ Konsep Utama dari Neural Network itu adalah Perancangan Struktur end to end yang iteratif dan murni berorientasi pada optimasi bobot/weight (kurang lebih sama seperti Model Linear Regresi).

Model Neural Network ini mewajibkan kita membangun struktur dari end to end, yaitu dimulai dari Input Layer, dimana pada Input Layer semua Variabel/kolom data kita terdefinisi sebagai neuron yang mana Neuron-neuron pada Input Layer ini akan diproses di hidden layer. Hidden Layer berfungsi mendampingi neuron³ dari Input layer dengan parameter yg nanti teritorasi (Weight dan bias).

~~Setiap~~ Setiap neuron pada Input layer dihubungkan ke semua neuron yang ada pada neuron untuk Semuanya di kalkulasikan bobot nya. Oiya kenapa neuron pada Hidden Layer di set banyak; puluhan, bahkan ratusan?

ini dilakukan karena untuk meningkatkan kemampuan representasi model, Mempelajari Pola yang kompleks dan non linear, Yaitu agar Model yg kita bangun ini Reliable.

Ex. $n_3 = n_1 \cdot \text{Weight}(3,1) + n_2 \cdot \text{Weight}(3,2) + b_3 \rightarrow \sigma(n_3)$


$n_4 = n_1 \cdot \text{Weight}(4,1) + n_2 \cdot \text{Weight}(4,2) + b_4 \rightarrow \sigma(n_4)$

$n_5 = \sigma(n_3) \cdot \text{Weight}(5,3) + \sigma(n_4) \cdot \text{Weight}(5,2) + b_5 \rightarrow \text{Output}$

Seluruh sumbu neuron di hidden layer terkalkuluskan bobot dan biasnya.

Kemudian setiap output perhitungan neuron di hidden layer dikenakan fungsi aktivasi. Inilah yg juga menjadi pembedanya dari pada model regresi linear pada ML tradisional. fungsi non linear ini memungkinkan jaringan mempelajari pola rumit dan kompleks dalam data. Misal fungsi aktivasi seperti ReLU ($\max(0, b)$), Sigmoid ($\frac{1}{1+e^{-z}}$), dst.

Sumbu perhitungan fungsi aktivasi dari semua neuron di hidden layer kemudian collapse ke dalam satu pengukuran / satu neuron untuk mendapat hasil prediksi.



Untuk mengukur nilai keterakuratan model neural network ini dengan label sebenarnya, dilakukan perhitungan dengan menghitung fungsi kerugian (loss function) dari output. Misal fungsi kerugian yg sederhana seperti Mean Square error $\rightarrow (y - \hat{y})^2$. Kemudian loss function tersebut akan diiterasi sampai konvergen (minimum) dengan menghitung gradient loss function terhadap setiap bobot dan bias dalam proses sebelumnya. Istilah ini diketahui dalam pt algoritma Backpropagation atau dikenal Training data.

XX Backpropagation

Backpropagation Sesuai dengan namanya yg berarti algoritma ini berjalan mundur dari layer terakhirnya ke awal. Backpropagation dilakukan untuk men-train data yakni meng-adjust trap bobot dan bias yg telah dilalui forward pass sebelumnya dengan menghitung gradient nya untuk meminimalkan kesalahan..

Algoritma ini didukungi oleh Loss function, misal pada perhitungan mi mampat

$$MSE \Leftrightarrow L = (y_{true} - y_{pred})^2$$

* Backpropagation (Implementasi dari Coding)

•> Gradient terhadap output (a_3)

Cari turunan seberupa salah predksi model thd output

$$L = (\gamma_{true} - a_3)^2$$

$$\frac{\partial L}{\partial a_3} = -2(\gamma_{true} - a_3) \rightarrow \text{turunan rata-rata}$$

•> hitung Gradient terhadap z_3 (Input aktivasi output)

$$\frac{\partial L}{\partial z_3} = \frac{\partial L}{\partial a_3} \cdot \frac{\partial a_3}{\partial z_3} \rightarrow a_3 = \sigma(z_3)$$

$$\frac{\partial L}{\partial z_3} = -2(\gamma - a_3) \cdot \sigma'(z_3)$$

↓
turunan Loss ↓
turunan Sigmoid
thd output

•> hitung Gradient thd latih output
($W=0, B=0$)

$$\therefore z_3 = a_1 \cdot W_0[0] + a_2 \cdot W_0[1] + B_0$$

$$\frac{\partial L}{\partial W_0[0]} = \frac{\partial L}{\partial z_3} \cdot \frac{\partial z_3}{\partial W_0[0]} = \frac{\partial L}{\partial z_3} \cdot a_1$$

$$\frac{\partial L}{\partial W_0[1]} = \frac{\partial L}{\partial z_3} \cdot \frac{\partial z_3}{\partial W_0[1]} = \frac{\partial L}{\partial z_3} \cdot a_2$$

$$\frac{\partial L}{\partial B_0} = \frac{\partial L}{\partial z_3} \cdot 1$$

$$\sigma = \frac{1}{1+e^{-x}} = \frac{d}{dx} \sigma = \frac{d}{dx} \left(\frac{1}{1+e^{-x}} \right)$$

$$\sigma' = -1 \cdot (1+e^{-x})^{-2} \cdot (-e^{-x}) \\ = \frac{e^{-x}}{(1+e^{-x})^2}$$

$$\sigma'(x) = \frac{1}{1+e^{-x}} \cdot \frac{e^{-x}}{1+e^{-x}} \\ = \sigma(x) \cdot \frac{e^{-x}}{1+e^{-x}}$$

$$\frac{e^{-x}}{1+e^{-x}} \Rightarrow \text{kita manipulasi bentuknya ke } \sigma(x)$$

$$\frac{e^{-x}}{1+e^{-x}} + \frac{1}{1+e^{-x}} = 1 \Rightarrow 1 - \sigma(x)$$

$$\therefore \sigma'(x) = \sigma(x) (1 - \sigma(x))$$

↳ hitung gradien terhadap hidden Layer (a_1, a_2)

$$\frac{\partial f}{\partial a_1} = \frac{\partial f}{\partial z_3} \cdot \frac{\partial z_3}{\partial a_1} = \frac{\partial f}{\partial z_3} \cdot W_o[0]$$

$$\frac{\partial f}{\partial a_2} = \frac{\partial f}{\partial z_3} \cdot \frac{\partial z_3}{\partial a_2} = \frac{\partial f}{\partial z_3} \cdot W_o[1]$$

↳ hitung gradien terhadap z_1, z_2 (input aktivasi hidden)

$$\frac{\partial L}{\partial z_1} = \frac{\partial L}{\partial a_1} \cdot \frac{\partial a_1}{\partial z_1} = \frac{\partial L}{\partial a_1} \cdot \sigma'(z_1)$$

$$\frac{\partial L}{\partial z_2} = \frac{\partial L}{\partial a_2} \cdot \frac{\partial a_2}{\partial z_2} = \frac{\partial L}{\partial a_2} \cdot \sigma'(z_2)$$

↳ hitung gradien terhadap bukti input (W_h, B_h)

1 neuron hidden pertama $\rightarrow z_1 = x_0 \cdot W_h[0][0] + x_1 \cdot W_h[1][0] + B_h[0]$

$$\frac{\partial L}{\partial W_h[0][0]} = \frac{\partial L}{\partial z_1} \cdot \frac{\partial z_1}{\partial W_h[0][0]} = \frac{\partial L}{\partial z_1} \cdot x_0$$

$$\frac{\partial L}{\partial W_h[1][0]} = \frac{\partial L}{\partial z_1} \cdot \frac{\partial z_1}{\partial W_h[1][0]} = \frac{\partial L}{\partial z_1} \cdot x_1$$

$$\frac{\partial L}{\partial B_h[0]} \cdot \frac{\partial z_1}{\partial B_h[0]} = \frac{\partial L}{\partial z_1}$$

* neuron hidden kedua $\rightarrow z_2 = x_0 \cdot W_h[0][1] + x_1 \cdot W_h[1][1] + B_h[1]$

$$\frac{\partial L}{\partial W_h[0][1]} = \frac{\partial L}{\partial z_2} \cdot \frac{\partial z_2}{\partial W_h[0][1]} = \frac{\partial L}{\partial z_2} \cdot x_0$$

$$\frac{\partial L}{\partial W_h[1][1]} = \frac{\partial L}{\partial z_2} \cdot \frac{\partial z_2}{\partial W_h[1][1]} = \frac{\partial L}{\partial z_2} \cdot x_1$$

$$\frac{\partial L}{\partial B_h[1]} = \frac{\partial L}{\partial z_2}$$